

LSTM Tabanlı Bitcoin Fiyat Tahmin Modelleri: Kapsamlı Bir Literatür Taraması

Giriş

Küresel finansal ekosistemin en yıkıcı inovasyonlarından biri olarak kabul edilen Bitcoin, merkeziyetsiz yapısı, şifreleme protokolleri ve eşler arası işlem ağı ile geleneksel para politikalarından bağımsız, alternatif bir varlık sınıfı oluşturmuştur.¹ Geleneksel itibari para birimlerinin (fiat) aksine, Bitcoin'in piyasa değeri; arz-talep dengesizlikleri, makroekonomik dalgalanmalar, düzenleyici kurumların reaksiyonları, teknolojik güncellemeler, ağ üzerindeki zincir içi (on-chain) metrikler ve en önemlisi yatırımcı duyarlılığı (market sentiment) gibi çok boyutlu ve heterojen faktörlerin baskısı altında son derece yüksek bir volatilité sergilemektedir.² Bu yapısal oynaklık ve geleneksel finansal varlıklara kıyasla sahip olduğu güçlü doğrusal olmayan (non-linear) dinamikler, Bitcoin fiyat tahminini istatistiksel analiz ve finansal modelleme alanlarındaki en zorlu problemlerden biri haline getirmiştir.⁴

Tarihsel olarak, finansal zaman serilerinin modellenmesinde ve tahmin edilmesinde Otoregresif Hareketli Ortalama (ARIMA), Genelleştirilmiş Otoregresif Koşullu Değişen Varyans (GARCH) ve Prophet gibi geleneksel ekonometrik modeller kullanılmıştır.⁵ Ancak bu geleneksel modeller, büyük ölçüde verilerin durağan (stationary) olduğu veya belirgin bir mevsimsellik (seasonality) içerdiği varsayımına dayanmaktadır. Literatürdeki kapsamlı incelemeler, kripto para piyasalarında belirgin bir mevsimselliğin bulunmaması ve fiyatların kaotik şoklara maruz kalması nedeniyle, ARIMA ve Prophet gibi yöntemlerin öngörü kapasitelerinin yetersiz kaldığını kesin bir dille ortaya koymaktadır.⁴ Bu yapısal kısıtlamalar, araştırmacıları çok boyutlu büyük veri setlerindeki karmaşık, uzun vadeli ve doğrusal olmayan örüntüleri (patterns) öğrenebilen Makine Öğrenmesi (ML) ve Derin Öğrenme (DL) tekniklerine yönlendirmiştir.⁶

Yapay Zeka (AI) tabanlı yaklaşımlar arasında, özellikle zaman serisi analizi için tasarlanmış ve optimize edilmiş bir Tekrarlayan Sinir Ağı (Recurrent Neural Network - RNN) mimarisi olan Uzun Kısa-Vadeli Hafıza (Long Short-Term Memory - LSTM) ağları, kripto para tahmin literatüründe endüstri standardı haline gelmiştir.³ Standart RNN modellerinin çok katmanlı ağlarda geriye yayılım (backpropagation) esnasında yaşadığı kaybolan gradyan (vanishing gradient) problemini kendi bünyesindeki matematiksel geçit (gate) mekanizmaları sayesinde aşan LSTM, verilerdeki zamansal bağımlılıkları (temporal dependencies) muazzam bir isabet oranıyla modeller.⁵

2021 ve 2025 yılları arasında yayımlanan 130 hakemli bilimsel makaleyi inceleyen Sistemik Literatür Taraması (SLR) çalışmaları, kripto tahmin ekosisteminin dört ana kümeye ayrıldığını göstermektedir: derin öğrenme mimarileri (özellikle LSTM ve varyantları), sosyal medya tabanlı duyarlılık analizi, teknik ve zincir içi metrikler ve hibrit tahmin çerçeveleri.³ Bu kapsamlı araştırma

raporu, Bitcoin fiyat tahmininde LSTM mimarisinin kullanımına odaklanan en güncel ampirik bulguları sentezlemektedir. İzole derin öğrenme modellerinden başlayarak, sinyal ayrıştırma teknikleriyle (VMD, CEEMDAN) desteklenmiş, duyarlılık analizi algoritmalarıyla (FinBERT) bütünleştirilmiş, uzamsal özellikleri analiz eden CNN ağlarıyla birleştirilmiş ve metasezgisel optimizasyon araçlarıyla (Optuna, Genetik Algoritmalar) rafine edilmiş en modern hibrit ekosistemler detaylı ve analitik bir düzlemde incelenmektedir.

LSTM Mimarisinin Matematiksel Temelleri ve Finansal Zaman Serilerindeki Rolü

Zaman serisi tahmininin kavramsal temelinde, geçmiş zaman dilimlerindeki olayların ve veri noktalarının gelecekteki durumlar üzerinde stokastik veya nedensel bir etkiye sahip olduğu varsayımı yatar.¹² Klasik çok katmanlı algılayıcıların (Multilayer Perceptron - MLP) aksine, LSTM ağları ardışık veri işleme kapasitesine sahip olup, ağ içindeki gizli durumlar (hidden states) ve bellek hücreleri (memory cells) aracılığıyla geçmiş bilgileri dinamik bir "hafıza" olarak korur. Bitcoin gibi sürekli spekülasyon şokları barındıran serilerde, bir modelin hangi bilgiyi unutması ve hangi bilgiyi geleceğe taşıması gerektiğine karar verebilmesi tahminin doğruluğu açısından hayati önem taşır. LSTM, bu bilgi filtreleme işlemini diferansiyellenebilir geçit mekanizmaları (gating mechanisms) ile gerçekleştirir.¹¹

t zaman adımında, modele sunulan girdi vektörü $x_t \in \mathbb{R}^n$, bir önceki adımın gizli durumu $h_{t-1} \in \mathbb{R}^m$ ve bir önceki hücre durumu $c_{t-1} \in \mathbb{R}^m$ olmak üzere, bir LSTM hücresinin içsel matematiksel güncellemeleri şu denklemler matrisi ile ifade edilir ⁶:

1. **Unutma Geçidi (Forget Gate - f_t):** Modelin, mevcut hücre durumundan (c_{t-1}) hangi bilgilerin tamamen silineceğine veya ne oranda korunacağına karar verdiği ilk aşamadır. Ani, temelsiz ve kalıcı olmayan bir piyasa şoku (örneğin sahte bir regülasyon haberi) yaşandığında, bu geçit eski anlamsız verileri sönmüler.

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$

2. **Girdi Geçidi (Input Gate - i_t) ve Aday Hücre Durumu (g_t):** Girdi geçidi, hücre durumuna hangi yeni ve geçerli bilgilerin ekleneceğini belirler. Lojistik sigmoid fonksiyonu ile hesaplanan i_t geçidi güncellenecek değerleri seçerken, hiperbolik tanjant fonksiyonu ($\tanh$) kullanan g_t (bazı literatürlerde $\tilde{c}_t$) vektörü ağa eklenecek yeni aday değerleri oluşturur.

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$$

$$g_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$$

3. **Hücre Durumunun Güncellenmesi (Cell State Update - c_t):** Eski hücre durumu c_{t-1} , unutma geçidi ile eleman bazlı çarpılarak gereksiz bilgilerden arındırılır. Ardından, girdi geçidi ve aday vektörün çarpımı sisteme entegre edilir. Bu doğrusal toplama işlemi, uzun vadeli eğilimlerin (örneğin Bitcoin'deki dört yıllık halving döngülerinin veya makro boğa piyasalarının) kaybolmadan ağ boyunca güvenle taşınmasını sağlar.

$$c_t = f_t \circ c_{t-1} + i_t \circ g_t$$

4. **Çıktı Geçidi ve Yeni Gizli Durum (Output Gate & Hidden State - o_t, h_t):** Çıktı geçidi, güncellenmiş hücre durumunun filtrelenerek ağın bir sonraki derinlik katmanına veya bir sonraki zaman adımına aktarılacak olan asıl kısmını belirler.

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$$

$$h_t = o_t \circ \tanh(c_t)$$

Denklemlerdeki σ standart lojistik sigmoid fonksiyonunu (değerleri 0 ile 1 arasına sıkıştırır), $\circ$ işareti Hadamard çarpımını (vektörlerin karşılıklı eleman bazlı çarpımı) temsil eder. Ayrıca W_*, U_* ağın eğitim sürecinde sürekli olarak optimize edilen öğrenilebilir ağırlık matrislerini, b_* ise sapma (bias) vektörlerini ifade eder.¹¹ Sigmoid fonksiyonunun doğası gereği geçitler 0 ile 1 arasında değerler üretir; 0 değeri matris çarpımı yoluyla verinin "tamamen bloke edilmesini", 1 ise bilginin "tamamen geçirilmesini" ifade eder. Bu dinamik, LSTM'in Bitcoin fiyatlarındaki anlık, gürültülü dalgalanmaları (market noise) izole etmesine ve piyasanın temel yapısal trendlerini hafızasında tutmasına olanak tanır.

Klasik RNN algoritmalarının finansal tahminlerde başarısız olmasının en büyük nedeni, geriye dönük pencere boyutu (lookback window) genişledikçe, zincir kuralı gereği türevlerin ardışık olarak çarpılması ve bu durumun gradyanların sıfıra yaklaşmasına (vanishing gradient) yol

açmasıdır.⁸ LSTM'deki eklemeli (additive) yapı (c_t denklemindeki artı operatörü), gradyanların hücre durumu boyunca kesintisiz bir otoyol (gradient highway) gibi geriye doğru akmasını sağlar. Böylece model, aylar öncesine dayanan makro destek-direnç bölgelerini dahi unutmaz.⁸

Veri Ön İşleme, Özellik Mühendisliği (Feature

Engineering) ve Gösterge Matematiği

Derin öğrenme modellerinin performans tavanı, hiperparametrelerden çok, modele beslenen verinin kalitesine, temizliğine ve bilgi yoğunluğuna (information density) bağlıdır.³ Araştırmalar, salt kapanış fiyatlarının kullanımından ziyade, karmaşık özellik mühendisliği (feature engineering) süreçleriyle boyutlandırılmış çoklu veri setlerinin, LSTM ve hibrit modellerin yönsel doğruluğunu (directional accuracy) radikal biçimde artırdığını göstermektedir.¹²

Tarihsel Fiyat Dinamikleri ve Gelişmiş Teknik Göstergeler

Standart bir Bitcoin tahmin veri seti, geleneksel olarak OHLCV (Açılış, Yüksek, Düşük, Kapanış, Hacim) formatındaki günlük veya yüksek frekanslı zaman serilerinden oluşur.¹ Ancak finansal varlıkların doğrusal olmayan bağımlılıklarını yansıtmakta tek başına OHLCV yetersiz kalır. Modelin; fiyatın piyasa ivmesini, oynaklık katsayısını, hareketli ortalamalara göre konumunu ve yatırımcıların aşırı alım/aşırı satım tepkilerini algılayabilmesi için aşağıdaki matematiksel hesaplamalara dayanan ek nitelikler (features) sıklıkla matrislere entegre edilmektedir⁶:

- **Getiri Oranı (Rate of Return):** Finansal analizde fiyat serisinin durağanlaştırılması (stationarity) oldukça kritiktir. Çoğu çalışma, doğrudan fiyat yerine logaritmik veya yüzdelik getiri oranlarını hedefler. Günlük getiri oranı şu şekilde hesaplanır¹²:

$$Return_t = \frac{P_t - P_{t-1}}{P_t}$$

- **Fiyat Varyansı (Price Variance):** Varlık fiyatlarındaki istatistiksel sapmayı ölçer. 10 günlük ve 20 günlük varyans pencereleri modele piyasa volatilitesi hakkında ön bilgi verir.¹²
- **Bollinger Bantları (Bollinger Bands - Boll Index):** John Bollinger tarafından geliştirilen bu indeks, varlık fiyatının istatistiksel oynaklığını ve olası geri dönüş güven aralıklarını belirlemek için fiyatın N günlük basit hareketli ortalaması ve standart sapması (σ_B) üzerinden modellenir.¹² Modelin üst veya alt banda teması bir destek/direnç kırılımı sinyali olarak öğrenmesini sağlar:

$$Boll_t = \frac{\sum_{n=1}^N P_{t-n}}{N} \pm 2\sigma_B$$

- **Psikolojik İndeks (Psychological Index - Psy):** Varlık piyasasında yatırımcıların psikolojik dalgalanmalarının duyarlılığını ölçer. N gün içerisindeki fiyatın yükseldiği günlerin sayısının (N_{up}), toplam güne (N) oranlanmasıyla elde edilir¹²:

$$Psy_t = \frac{N_{up}}{N}$$

- **Göreceli Güç Endeksi (RSI):** Piyasadaki aşırı alım (overbought) veya aşırı satım (oversold) seviyelerini sayısal bir değere dönüştüren temel osilatördür.⁶ Model, fiyatın trend yönündeki gücünü bu endeks ile tartarak olası düzeltmeleri (pullback) tahmin eder.

RSI formülasyonu, yükseliş günlerinin (r_{t-i}) ve düşüş günlerinin (f_{t-i}) toplam fiyat değişimlerini baz alır¹²:

$$RSI = 100 - \frac{100}{1 + (\frac{1}{n} \sum_{i=0}^n r_{t-i}) / (\frac{1}{n} \sum_{i=0}^n f_{t-i})}$$

- **Fibonacci Geri Çekilme Seviyeleri:** Fiyat düzeltmelerindeki destek ve direnç bölgelerinin belirlenmesinde kullanılan bu oranların veri setine eklenmesi, model performansını ve ticari yatırım getirisini (ROI) büyük ölçüde artırmaktadır.¹³ Özellikle 1 dakikalık yüksek frekanslı verilerde (HFT) C-LSTM (Convolutional LSTM) modellerine bu seviyelerin entegrasyonu, trendin güç sınıflandırmasında %31.71'lik bir iyileşme sağlamış, yatırım getirisinde (ROI) ise %45'lere varan bir sıçrama yaratmıştır.¹³

Rastgele Orman (Random Forest), Boruta ve SHAP ile Özellik Seçimi

Tarihsel fiyat, 50'den fazla teknik indikatör, sosyal medya duyarlılık verisi ve on-chain (zincir içi) değişkenlerin tamamının filtrelenmeden doğrudan yapay zeka ağına verilmesi, finansal modellemede boyutluluk laneti (curse of dimensionality) ve aşırı öğrenme (overfitting) problemlerini tetikler.⁵ Özellik seçimi (feature selection), bu nedenle veri ön işleme hattının en hayati bileşenidir.

Literatürdeki metodolojiler, gereksiz veya gürültü (noise) oluşturan göstergeleri algoritmik olarak elemek için Rastgele Orman (Random Forest - RF), Boruta algoritmaları ve SHAP (Shapley Additive Explanations) oyun teorisi tekniklerini devreye sokmaktadır.⁵ Random Forest algoritması, çoklu karar ağaçları üzerinden özelliklerin (features) modelin doğruluğuna olan Gini safsızlığı veya bilgi kazancı gibi ölçütlerle katkısını (feature importance) belirler ve en az etkiye sahip değişkenleri veri matrisinden çıkarır.⁵ Bu boyut indirgeme adımı sayesinde LSTM, yalnızca Bitcoin'in gelecekteki fiyatını belirlemede istatistiksel önemi olan en rafine sinyallerle eğitilir.⁵ Ayrıca SHAP değerleri, modele Açıklanabilir Yapay Zeka (Explainable AI - XAI) katmanı kazandırarak, her bir zaman adımında (örneğin 1 Ocak 2021 tarihindeki Bitcoin tahmininde) modelin ağırlıklı olarak hangi girdiye (örn., RSI verisi mi yoksa o günkü işlem hacmi mi) dayanarak karar verdiğini yatırımcıya objektif olarak sunar.⁶

Temel Derin Öğrenme Mimarilerinin Performans

Karşılaştırması: RNN, LSTM, GRU ve Bi-LSTM

Finansal tahmin literatürü, zaman serisi analizinde Recurrent Neural Network (RNN) ailesine mensup dört temel yapıyı sıkı bir biçimde birbiriyle rekabet ettirmektedir: Standart RNN, LSTM, Geçitli Tekrarlayan Birim (GRU) ve Çift Yönlü LSTM (Bi-LSTM).⁸ Bu mimariler yapısal karmaşıklık, parametre yoğunluğu ve bilgi saklama süreleri bakımından önemli farklılıklar gösterir.

Standart RNN ve LSTM Karşılaştırması

Yapılan ampirik testlerde, standart RNN yapısının geçmiş verileri sınırlı bir hücre yapısında tutmaya çalışması ve çok hızlı bir şekilde gradyanlarını kaybetmesi nedeniyle hata oranlarının yıkıcı derecede yüksek olduğu saptanmıştır. Optuna ile optimize edilmiş hibrit ağ deneylerinde standart RNN tabanlı modelin test doğruluğu %5.45 gibi işlevsiz bir seviyede kalırken, aynı parametre ortamındaki LSTM tabanlı model %52.78 doğruluk elde ederek zaman serisi görevlerindeki salt yapısal üstünlüğünü kanıtlamıştır.¹⁸

LSTM ve GRU Arasındaki Rekabet

LSTM ile GRU arasındaki karşılaştırmalarda ise daha dengeli bir bilimsel tartışma göze çarpmaktadır. GRU (Gated Recurrent Unit), LSTM'in hücre durumu (c_t) ve gizli durum (h_t) kavramlarını tek bir durumda birleştirmiş; unutma ve girdi geçitlerini "güncelleme geçidi" (update gate) altında toplamıştır. Bu modifikasyonlar mimariyi sadeleştirmiş, eğitilecek parametre sayısını azaltmış ve hesaplama (computational) hızını maksimize etmiştir.¹³ Bu mimari hafiflik, aşırı öğrenmeyi (overfitting) önlemede çoğu zaman ciddi bir avantaj sağlamaktadır. Nitekim üç farklı kripto para (BTC, ETH, LTC) üzerinde yapılan kapsamlı bir hata analizinde, GRU modellerinin LSTM'den daha düşük Ortalama Mutlak Yüzde Hata (MAPE) ürettiği bulunmuştur. GRU, Bitcoin için %3.54 (0.0354), Litecoin için %8.7 ve Ethereum için %4.41 MAPE skoru üretirken LSTM'i geride bırakmıştır.¹³ Başka bir güncel çalışmada GRU, Bitcoin verilerinde %0.38 MAPE, 343.02 RMSE ve 0.9988 R^2 elde ederek yine standart LSTM'i (%0.41 MAPE, 356.01 RMSE) çok ufak bir marjla geçmiştir.¹⁹

Dikkat çekici bir diğer bulgu ise optimal geriye dönük pencere (lookback window) boyutlarındaki ayrımdır. LSTM modelleri, son derece kısa bir bağlam penceresinde ($L = 1 - 2$ gün) dahi optimal performansa ulaşır kısa vadeli ani kırılımları öğrenebilirken; GRU modelleri geçmiş bilgiyi yorumlamak için çok daha geniş bir pencereye ihtiyaç duymuş ve manuel hiperparametre ayarlarında $L = 59$ seviyesinde en düşük Ölçeklenmiş Mutlak Hataya (Scaled MAE = 0.0271) erişebilmiştir.²⁰

Çift Yönlü LSTM (Bi-LSTM) ve Bağlamsal Derinlik

Geleneksel Tek-Yönlü LSTM ve GRU mimarilerinin ortak kısıtlaması, zaman serisi vektörünü yalnızca geçmişten geleceğe (soldan sağa) doğru tek yönde işlemeleridir.⁸ Finansal piyasalarda,

geriye dönük model eğitimlerinde veya eksik verilerin ara-değer atama (imputation) süreçlerinde, varlık fiyatlarının bağlamsal konumunu sadece geçmiş reaksiyonlara değil, serideki olaylardan hemen sonra gelen verilere (future data) de dayandırmak, modelin yapısallığı çok daha net kavramasına yol açar.⁵ Çift Yönlü LSTM (Bi-LSTM), giriş verisini aynı anda iki bağımsız gizli katmanda işler; katmanlardan biri veriyi ileri ($t = 1 \dots N$), diğeri geri ($t = N \dots 1$) yönde analiz eder ve bu iki katmanın çıktıları nihai adımda birleştirilir.⁵

2023 yılında Seabe ve arkadaşları tarafından yapılan karşılaştırmalı bir çalışmada, kripto paraların fiyat tahmininde Bi-LSTM'in, standart LSTM ve GRU modellerini tutarlı bir biçimde geride bıraktığı ispatlanmıştır.⁸ Kripto piyasasının öngörülemez oynaklığı içinde, bilginin çift yönlü akışı, geçici gürültülerin model tarafından daha hızlı absorbe edilmesine ve yapısal kırılmaların ağ tarafından çok daha berrak bir biçimde algılanmasına imkan vermektedir.⁸

İleri Seviye Sinyal Ayırıştırma Çerçevesi: VMD ve CEEMDAN

Finansal zaman serilerinin tahmin edilmesindeki en büyük teorik bariyer, verilerin "stokastik ve durağan olmayan" (non-stationary) doğasıdır. Fiyat dalgalanmalarının farklı frekanslarda ve rastgele genliklerde gerçekleşmesi, verilerin doğrudan modellenmesini ağ için zorlaştırır. Son yıllarda literatürdeki en devrimsel atımlardan biri, ham Bitcoin fiyat sinyalinin, LSTM ağına doğrudan beslenmeden önce matematiksel bir ön işlemden geçirilerek daha basit, durağan ve bağımsız alt bileşenlere ayrıştırılması olmuştur.² Bu alanda iki belirgin teknik literatürü domine etmektedir:

Varyasyonel Mod Ayırıştırması (Variational Mode Decomposition - VMD)

VMD, tamamen veri güdümlü ve tamamen uyarlanabilir bir sinyal işleme tekniğidir. Karmaşık bir zaman serisi sinyalini, matematiksel bir kısıtlı varyasyonel optimizasyon problemi çözerek, her biri sınırlı bir bant genişliğine sahip ve tahmini bir merkez frekansı etrafında toplanmış olan İçsel Mod Fonksiyonlarına (Intrinsic Mode Functions - IMF) böler.²

Bu metodolojinin kripto para birimlerine uygulandığı bir çalışmada, Yahoo Finance üzerinden çekilen 2017-2025 yıllarını kapsayan Bitcoin fiyat serisi, VMD algoritması ile ampirik olarak test

edilmiş en uygun ayırıştırma sayısı olan $K = 15$ adet IMF'ye bölünmüştür.² Her bir ayrıştırılmış frekans bileşeni (yüksek frekanslı günlük piyasa gürültüsünden, düşük frekanslı multi-yıllık makro trendlere kadar), kendine ait ayrı bir LSTM modeli tarafından modellenmiştir. İlgili çalışmada bu alt-LSTM modelleri, 30 günlük geriye dönük lookback penceresi kullanılarak, Adam optimizasyon algoritması, Ortalama Kare Hata (MSE) kayıp fonksiyonu, 20 epoch eğitimi ve 32 batch size (yığın boyutu) parametreleri ile eğitilmiştir.²

Ayrıştırılmış modellerin her biri, kendi frekans bandına odaklanarak gelecekteki 30 değeri tahmin eder. Son aşamada (Ensemble / Topluluk), bu 15 alt tahmin matematiksel olarak basit bir

toplama işlemiyle birleştirilir:

$$\hat{y}(t) = \sum_{k=1}^K \hat{y}_k(t)$$

VMD-LSTM hibrit çerçevesi, standart LSTM'e kıyasla test verilerinde yüksek frekanslı volatilitenin modelin kafasını karıştırmasını engellemiş ve RMSE, MAE ve R-kare metriklerinin tümünde çarpıcı bir performans artışı sağlamıştır.²

Uyarlanabilir Gürültülü Tam Topluluk Ampirik Mod Ayırışımı (CEEMDAN)

Ampirik Mod Ayırışımı (EMD) yöntemlerindeki en büyük sorun olan "mod karışımı" (mode mixing) problemini çözmek amacıyla geliştirilmiştir. CEEMDAN, her ayırıştırma adımına matematiksel olarak hesaplanmış seviyelerde adaptif beyaz gürültü (adaptive white noise) ekleyerek, sinyalin pürüzsüz ve gerçek fiziksel/ekonomik döngüler halinde ayırışmasını sağlar.²²

Literatürdeki çeşitli çalışmalarda CEEMDAN-LSTM modellerinin, salt LSTM veya diğer ağlara (ör. ARIMA) göre performansı ölçülmüştür. Bu ön işleme metodunun modele sağladığı katkı muazzamdır: Tüm test edilen finansal veri setlerinde, CEEMDAN tabanlı algoritmalar Ortalama Mutlak Hatayı (MAE) %65 ile %90 oranında, Hata Kareler Ortalaması Karakökünü (RMSE) ise %60 ile %85 oranında azaltmayı başarmıştır.²² Bitcoin spesifik tahminlerde ise CEEMDAN-LSTM model kombinasyonlarının MAPE oranını inanılmaz bir seviye olan %0.04'e kadar çekebildiği ve karmaşık frekans alt-sekanslarını çok yüksek isabetle öğrenebildiği ispatlanmıştır.²⁴

Hibrit Makine Öğrenmesi ve Derin Öğrenme

Mimarileri

Sadece LSTM modellerine dayanmak, modelin doğrusal olmayan makro istatistiksel değişkenleri kavramasında limitler doğurur. En ileri seviye araştırma yaklaşımları, farklı yapay zeka paradigmalarının güçlü yönlerini (feature extraction, temporal sequence learning, gradient boosting, error optimization) aynı mimari içerisinde eriten "Hibrit Modeller" etrafında toplanmıştır.¹

LSTM ve XGBoost Entegrasyonu

Derin öğrenme modelleri (LSTM), zamansal dizileri (sekans) analiz etmede rakipsizdir; ancak ağaç tabanlı (tree-based) makine öğrenmesi modelleri (örneğin Extreme Gradient Boosting - XGBoost), doğrusal olmayan ilişkileri eşleştirmede, asimetrik karar ağaçları kurmada ve özellik önemini saptamada olağanüstü bir analitik kapasiteye sahiptir.¹

Bu doğrultuda geliştirilen LSTM+XGBoost hibrit yaklaşımı, finansal tahmini iki aşamalı çözer. LSTM bileşeni tarihsel fiyat verilerindeki zamansal bağımlılıkları öğrenip kodlarken; XGBoost bu verileri makroekonomik değişkenler, hacim indikatörleri ve duyarlılık skorları ile genişleterek

yardımcı (auxiliary) özelliklerin fiyata olan doğrusal olmayan etkilerini analiz eder.¹ Min-Max Normalize RMSE ve MAPE metrikleri üzerinden yapılan çapraz analizler, LSTM+XGBoost topolojisinin gerek küresel borsalarda gerekse yerel kripto platformlarında, izole çalıştırılan geleneksel modelleri istikrarlı bir şekilde mağlup ettiğini kanıtlamıştır.¹ XGBoost ayrıca topluluk (ensemble) çerçevesi altında, CNN-LSTM'nin ürettiği zaman serisi hatalarını (residuals) öğrenip düzeltme mekanizması olarak da kullanılabilir ve tahmin hassasiyetini maksimize etmektedir.⁶

2D-CNN ve LSTM (Mekansal-Zamansal Özellik Çıkarımı)

Finansal veri setlerinde, özellikle çoklu değişkenlerin (farklı indikatörler, hacim ve alternatif kripto coin verileri) matris formunda sunulduğu durumlarda, değişkenler arasında anlık "mekansal" (spatial) veya çapraz varlık korelasyonları bulunur. Evrişimli Sinir Ağları (CNN), bilgisayarlı görüde piksel gruplarından özellik çıkardığı gibi, zaman serisi veri pencereleri (sliding window) üzerinde evrişim çekirdeklerini (convolutional kernels) gezdirerek yüksek seviyeli, gürültüden arındırılmış ve soyut özellik haritalarını filtreler.⁵

CNN katmanları gürültülü piyasa verilerinden en belirgin özellikleri (ör. ani hacim kırılımları) çıkardıktan sonra, boyutları MaxPooling ile küçültülmüş bu vektörler LSTM katmanına beslenir. Gelişmiş bir 2D-CNN LSTM mimarisi, test verilerinde CNN'in kısa vadeli trendleri algılama yeteneği ile LSTM'nin sekans belleğini birleştirerek, pazar hareketlerine diğer modellerden daha hızlı adaptasyon sağlamıştır.⁶

Dikkat (Attention) Mekanizması ile Zenginleştirilmiş Ağlar

Finansal zaman serisindeki her veri noktasının (örneğin bir ay önceki stabil bir işlem gününün), mevcut fiyat oluşumu üzerinde eşit derecede etkiye sahip olması mantığa aykırıdır. Piyasada yaşanan regülasyon kaynaklı bir düşüş şoku, geride kalan 20 günlük yatay veriden çok daha değerlidir. Dikkat (Attention) mekanizması, NLP alanındaki Transformer mimarisinden ilham alınarak LSTM'e dahil edilen ve ağırlı girdi dizisindeki en önemli "zaman adımlarına" matematiksel ağırlıklar (α_t) tahsis etmesini sağlayan akıllı bir dengeleme sistemidir.⁵

Matematiksel formülasyonda, t zamanındaki bağlam vektörü c_t dikkat ağırlıkları ile birleştirilir ve ağırlı sınırlı işlem kapasitesi sadece odaklanılması gereken kilit olaylara (anormal hacim artışlarına veya fiyat zıplamalarına) yönlendirilir.⁵ CNN-Bi-LSTM ağı ile Attention mekanizmasının birleştirilmesiyle oluşturulan modeller, özellik vektörünün (feature vector) ağırlığını dinamik olarak optimize ederek Bitcoin'in hiper-oyunaklığı içerisindeki "gerçek sinyali" "piyasa gürültüsünden" süzmektedir.¹⁴ Yapılan çalışmalarda, Attention mekanizmasına sahip bu modellerin %84.28'lere varan kısa vadeli Yönsel Doğruluk kapasitesine ulaştığı, geleneksel modellere kıyasla %12 daha başarılı olduğu ispatlanmıştır.⁶

Doğal Dil İşleme (NLP) ve Yatırımcı Duyarlılığı

(Sentiment Analysis)

Bitcoin ekosisteminin merkeziyetsiz yapısı ve geleneksel hisse senetlerindeki gibi bilanço, nakit akım tablosu veya gelir modeli (cash flow) yoksunluğu, fiyat oluşumunu arz/talep dengesine ve spekülasyonist yatırımcı duyarlılığına son derece hassas hale getirmektedir. Sosyal medya etkileşimleri (X/Twitter, Reddit paylaşımları), Google Trends arama hacimleri ve sektörel finansal haber akışları, Bitcoin'in saatlik fiyat kırılımları üzerinde bile dramatik bir tahminsel güce sahiptir.¹ Literatür, salt fiyat hareketleri yerine, metinsel bağlamı anlayan Bağlamsal Dil Modellerinin (Contextual Language Models) analiz süreçlerine dahil edilmesinin, ağların piyasa reaksiyonlarını modellemesinde devasa bir avantaj sağladığını tespit etmiştir.³

FinBERT-BiLSTM Çerçevesi

FinBERT, finansal sektör jargonuna ve yatırımcı psikolojisine hakim olmak üzere finansal metinler üzerinde önceden eğitilmiş (pre-trained), BERT mimarisine dayanan gelişmiş bir modeldir. Hossain ve araştırma ekibi (2024/2026), kripto piyasalarındaki piyasa duyarlılığının (market sentiment) fiyata "anlık tepkiler" ve "gecikmeli yansımalar" şeklinde iki farklı ekseninde etki ettiğini gözlemleyerek, literatüre **FinBERT-BiLSTM** modelini kazandırmışlardır.⁸

Bu yapıda, tarihsel fiyatları işleyen standart fonksiyon $f(x)$ ile hedef d günündeki doğal dil modeli tabanlı duyarlılık skoru s_d , aynı sinir ağına birleştirilir. Tahmin edilen kapanış fiyatı $\hat{p}_d$, şu denklem ile belirlenir⁸:

$$\hat{p}_d = f(x, s_d)$$

FinBERT-BiLSTM çerçevesi, derin öğrenme ile zaman serisi eğilimlerini kodlarken, FinBERT üzerinden çekilen metinsel panik (fear) veya coşku (greed) skorlarını doğrudan LSTM geçitlerine besler. Yapılan kapsamlı validasyon deneylerinde model; standart LSTM, Bi-LSTM, duyarlılık destekli varyantlar (FinBERT-LSTM) ve Transformer mimarileri (Informer, TCN, TimeGPT) dahil olmak üzere tüm son teknoloji yapıları mağlup etmiştir.²¹

Elde edilen Ortalama Mutlak Yüzde Hata (MAPE) metrikleri, modelin isabet gücünü kanıtlamaktadır²¹:

- **Gün İçi (Intra-day) Fiyat Tahmini:** BTC için %2.03, ETH için %2.52
- **Bir Gün Sonrası (One-Day-Ahead) Tahmini:** BTC için %2.20, ETH için %2.77
- **30 Gün Sonrası (30-Day-Ahead) Tahmini:** BTC için %1.62, ETH için %5.10

Dahası, bu çalışmalar zaman serisi modellerinin pratik değerlendirmesi için iki farklı eğitim metodolojisini literatüre tanıtmıştır⁸:

1. **Maksimum Veri Eğitimi (Maximum Data Training - MDT):** Modelin, test verisinden hemen önceki an'a kadar olan tüm geçmiş veriyi kullanarak eğitilmesi (doğrulama seti olmadan en geniş veri kullanımı).
2. **Doğrulama-Artırılmış Eğitim (Validation-Enhanced Training - VET):** Eğitim esnasında

bir doğrulama (validation) seti kullanarak en düşük doğrulama kaybına (validation loss) ulaşan model ağırlıklarının, geleceği tahmin etmek için sabitlenmesi. VET yöntemi, FinBERT-BiLSTM mimarilerinde modelin aşırı öğrenmesini engellemede daha istikrarlı (generalization) sonuçlar vermiştir.⁸

Model başarıları yalnızca hata metrikleriyle sınırlı kalmamış, FinBERT-BiLSTM bir "ticari yatırım stratejisi simülasyonuna" tabi tutulduğunda, duyarlılık-bilinçli algoritmaların pratik ticari değerini (trading profitability) muazzam şekilde ispatlayarak rakip modellerden çok daha karlı al-sat sinyalleri üretmiştir.²¹

Hiperparametre Optimizasyon Çerçevesi: Optuna ve Genetik Algoritmalar

Derin öğrenme modelleri (özellikle LSTM ve çok katmanlı mimariler) tasarımsal parametreleri (gizli katman sayısı, nöron adedi) ve eğitim argümanları (öğrenme oranı - learning rate, yığın boyutu - batch size, dropout oranları) açısından aşırı derecede hassastır.¹⁸ Yanlış yapılandırılmış bir LSTM, eğitim verisini ezberleyerek aşırı öğrenmeye (overfitting) düşebileceği gibi, yetersiz kapasite (underfitting) sebebiyle yerel minimumlarda (local minima) da takılı kalabilir.¹⁸

Geçmiş yıllardaki ızgara arama (grid search) veya rastgele arama (random search) gibi hesaplama maliyeti yüksek deneme-yanılma yöntemleri, yerini metasezgisel optimizasyon ve genetik arama algoritmaları ile otomatikleştirilmiş makine öğrenimi süreçlerine bırakmıştır.¹⁷

Optuna Framework ve Otomatize Hiperparametre Seçimi

Optuna, derin öğrenme algoritmaları için özel olarak dizayn edilmiş açık kaynaklı bir hiperparametre optimizasyon aracıdır. "Çalışma zamanında tanımla" (define-by-run) yaklaşımı ve Bayesyen Optimizasyon (Bayesian Optimization) tekniklerini kullanarak, modelin geçerlilik (validation) skorunu maksimize eden hiperparametre kombinasyonlarını zekice tarar ve en az denemede en yüksek başarıya ulaşır.⁴

Örneğin, gelişmiş bir 2D-CNN LSTM modelinin Bitcoin veri seti üzerinde Optuna ile optimize edildiği bir çalışmada, rastgele atamalarla asla bulunamayacak, modele özgü bir optimum yapılandırma tespit edilmiştir. İlgili Optuna denemelerinin sonucunda şu değerler optimal bulunmuştur: 130 LSTM birimi, 0.062 Dropout (Seyreltme) oranı, 122 Yoğun (Dense) katman birimi, 0.0028 Öğrenme Oranı (Learning Rate), 20 Yığın Boyutu (Batch Size) ve 28 Epoch

döngüsü.¹⁸ Bu parametrelerle yapılandırılan model, R^2 (Belirlilik Katsayısı) skorunu 0.98166'ya çıkartmış ve MAPE değerini %0.034'e kadar düşürerek literatürdeki en keskin öngörülerden birine imza atmıştır.¹³ Benzer biçimde, Optuna tabanlı bir Transformer modeli (OBOT)

kullanılarak gerçekleştirilen araştırmalarda da 0.0079 RMSE skoru elde edilerek çerçevenin optimizasyon kapasitesi teyit edilmiştir.⁴

Genetik Algoritmalar (GA) ve Evrimsel Yaklaşımlar

Darwinist doğal seçim süreçlerini taklit eden algoritmalar aracılığıyla evrimsel optimizasyon

sağlanır. RNN/LSTM tabanlı yapıların hiperparametrelerini "kromozomlar" olarak şifreleyen bu algoritmalar, çaprazlama (crossover) ve mutasyon fonksiyonlarıyla en güçlü yapıyı nesilden nesile aktarır. Literatürde zaman adımlarının (time steps), LSTM ünitesi sayısının ve ağ derinliğinin genetik algoritmalarca ayarlanmasının, hem kripto ekosisteminin asimetrik yapısına uygunluğu artırdığı hem de genellemeyi yükselttiği ampirik olarak kanıtlanmıştır.¹¹

Değerlendirme Metrikleri ve Karşılaştırmalı Performans Bulguları

Tahmin modellerinin regresyon görevlerindeki isabet oranlarını tarafsız (objektif) bir düzlemde karşılaştırmak adına literatürde standart istatistiksel hata fonksiyonları kullanılmaktadır. y_t hedeflenen gerçek fiyat, $\hat{y}_t$ modelin çıktısı olarak ürettiği tahmin ve n veri noktası sayısı olmak kaydıyla³³:

1. **Hata Kareler Ortalaması (MSE) ve Karekökü (RMSE):** Hata paylarının karesini alarak büyüklüğü cezalandırdığı için, modele aşırı sapan (outlier) veya tamamen yanlış trend tahminleri konusunda ciddi bir maliyet yükler. Kripto piyasasındaki anlık çöküş veya fırlama olaylarında (black swan), modelin ne kadar kararlı kaldığını ölçmek için en çok kullanılan metriktir.

$$MSE = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2 \quad ; \quad RMSE = \sqrt{MSE}$$

2. **Ortalama Mutlak Hata (MAE) ve Ortalama Mutlak Yüzde Hata (MAPE):** MAE hataların doğrudan mutlak değerini ifade eder ve sapan değerlere RMSE kadar agresif bir ceza vermez. MAPE ise hatayı mevcut varlık fiyatına bölerek yüzdelik bir skor (örn. %2 hata payı) ürettiği için, Bitcoin 3.000\$ iken yapılan testler ile 70.000\$ iken yapılan testlerin doğrudan karşılaştırılabilirliğini garanti altına alır.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100$$

Aşağıdaki tablo (Tablo 1), literatürde incelenen temel ve hibrit derin öğrenme mimarilerinin sağladığı ilerlemeleri ve genel performans bulgularını özetlemektedir:

Model Mimarisi / Yöntem	Ağ Yapılandırması ve Entegre Edilen	Karşılaştırmalı Performans Bulguları (Hata	İlgili Literatür Referansları
-------------------------	-------------------------------------	--	-------------------------------

	Yöntemler	Skorları)	
Saf LSTM	Yalnızca Tarihsel OHLCV, Tek Yönlü İşlem	%0.41 MAPE (BTC) / 356.01 RMSE. Geleneksel ARIMA ve MLP ağlarına göre mutlak üstünlük.	10
LSTM + GRU Kıyaslaması	GRU Optimizasyonu	Bazı optimizasyonlarda GRU %0.38 MAPE üreterek saf LSTM'e göre hesaplama hızı ve hata payında avantaj sağlamıştır.	13
Çift Yönlü LSTM (Bi-LSTM)	Geçmiş ve Gelecek Verisinin Eşzamanlı İşlenmesi	Çift yönlü bağlam kavrayışıyla LSTM ve GRU'dan daha istikrarlı (robust) zaman serisi tahmini.	5
VMD-LSTM	Varyasyonel Mod Ayırıştırması (15 İçsel Fonksiyon)	Sinyal durağanlaşır. Saf LSTM'ye göre RMSE ve MAE metriklerinde gözle görülür radikal bir düşüş; R-kare artışı.	2
CEEMDAN-LSTM	Adaptif Gürültülü Tam Topluluk Ayırışımı	MAE oranlarında %65-90, RMSE oranlarında %60-85'lere varan devasa hata	22

		azalmaları.	
2D-CNN LSTM (Optuna)	Mekansal Boyut İndirgeme + Hiperparametre Tarama	%0.034 MAPE. R^2 : 0.98166. Gürültü filtreleme, trend tespiti ve en uygun nöron/dropout atamalarının birleşimi.	13
FinBERT-BiLSTM	Doğal Dil İşleme (FinBERT) + Duyarlılık Ağırlıkları	Gün içi BTC: %2.03 MAPE; 30-Gün İleri ETH: %5.10 MAPE. Kripto oynaklığını aşmada mevcut dönemin en iyi sonuçlarından biri.	21
LSTM + XGBoost	Zamansal Bağımlılık (LSTM) + Doğrusal Olmayan (XGB)	Geleneksel yöntemlerden bariz biçimde üstün. Ekstra özelliklerin (auxiliary) hatalı kalıntıların düzeltme kapasitesi.	1

Literatürdeki Yöntemsel Eksiklikler ve Gelecek Araştırma Yönergeleri

Sistematik Literatür Taramaları (SLR), yapay zeka ve derin öğrenme ekosistemindeki muazzam teorik ilerlemelere rağmen, ampirik çalışmaların yürütülmesinde bazı tekrarlayan metodolojik kusurların bulunduğunu açığa çıkarmaktadır.³ Araştırmacıların akademik modellerin piyasada ticarileşmesini sağlayabilmesi için çözmesi gereken kritik darboğazlar şunlardır:

1. **Veri Sızıntısı (Data Leakage) ve Yanlış Eğitim-Test Bölünmesi:** Finansal zaman serilerinin modellenmesinde uyulması gereken temel kanun, zaman kısıtının (chronological sequence) titizlikle korunmasıdır. Eğitim (train) verileri mutlaka test verilerinden zaman olarak önce gelmelidir. Ancak 130 makale üzerinde yapılan eleştirel

analizlerde ³, hatırı sayılır miktarda araştırmancının veri setini "rastgele oranlarda" (random split, örn. genel verinin %80'i rastgele eğitim) böldüğü gözlemlenmiştir. Bu metodolojik hata, modelin gelecekteki bir veri noktasını eğitim aşamasında gizlice görmesine (data leakage) neden olmakta ve sonuç raporunda modelin sahte (over-optimistic) ve gerçekte ulaşamayacak kadar yüksek bir isabet oranı sunmasına yol açmaktadır. Test seti (out-of-sample) validasyonu mutlak suretle gelecekte olmalıdır.³

2. **Ekonomik Geçerlilik ve Ticari Validasyon Eksikliği:** Akademik camianın sadece kayıp fonksiyonlarını (Loss Functions) küçültmeye odaklanması bir diğer eksikliktir. Bir modelin istatistiksel hata payının düşük olması (örneğin düşük RMSE veya MAE skoru), bu modelle gerçek dünyada "kârlı" bir ticaret stratejisi kurulabileceği anlamına gelmez. Literatürdeki çalışmaların büyük çoğunluğu, oluşturulan LSTM mimarisinin pratik ekonomik getirisini (ROI) veya ticari geçerliliğini göz ardı etmektedir.³ Gelecek çalışmaların, basit hata metriklerini aşarak "Yönsel Doğruluk" (Directional Accuracy), yatırımdaki "Maksimum Düşüş" (Maximum Drawdown) ve alınan riske göre ayarlanmış getiri performansını sunan "Sharpe Oranı" (Sharpe Ratio) gibi finans dünyasının ana performans ölçütleriyle birleştirilmesi zorunludur.³
3. **Açıklanabilir Yapay Zeka (Explainable AI - XAI) İhtiyacı:** LSTM, CNN veya XGBoost gibi karmaşık derin ağlar, milyarlarca ağırlık hesabından oluştuğu için çıktıların nasıl ve neden üretildiğini dışarıdan gözlemlemenin imkansız olduğu "kara kutu" (black box) algoritmalarıdır. Kurumsal finans dünyasının ve regülatörlerin bu modellere sermaye veya güven bağlayabilmesi için kararların açıklanabilirliğine ihtiyaçları vardır. Özellikle SHAP (Shapley Additive Explanations) oyun teorisi değerlerinin LSTM modellerine entegrasyonu ¹³, ağın karar mekanizmasını aydınlatmaktadır. Örneğin, Bitcoin ağının o gün %10 düşeceğini öngören bir modelin; bu tahmini teknik hareketli ortalamalara dayanarak mı, yatırımcı duyarlılığı (FinBERT) panik seviyesine dayanarak mı, yoksa madenci cüzdanlarının satış baskısına dayanarak mı yaptığını yüzde (%) cinsinden raporlayabilmesi (Explainability), akademik bilginin finansal güvenilirlikle bulunduğu nokta olacaktır.⁶
4. **Alternatif Veri Akışlarının Geliştirilmesi:** Zincir içi metriklerin (on-chain metrics, örn: aktif cüzdan hareketlilikleri, borsalardaki Bitcoin rezervleri, MVRV oranı - Market Value to Realized Value) ve roBERTa gibi güncel bağlamsal dil modellerinin LSTM'ye daha sık dahil edilmesi ³, Bitcoin'in içsel dinamiklerini sadece borsa fiyat ekseninden çıkartacak; spekülasyona ilave olarak ağ ekonomisi ve madenci temel verileri üzerinden de mantıksal olarak fiyatlanmasına imkan tanıyacaktır.

Sonuç

Bu detaylı literatür taraması raporu, Bitcoin ve genel kripto para ekosisteminde fiyat tahmini süreçlerini yürütebilmek adına Uzun Kısa-Vadeli Hafıza (LSTM) tabanlı derin öğrenme ağlarının kat ettiği evrimsel çizgiyi bilimsel kanıtlarıyla gözler önüne sermektedir. Geleneksel ARIMA veya Prophet tabanlı istatistiksel analiz yöntemlerinin, hiçbir mevsimselliği olmayan, manipülasyonlara açık ve hiper-oynaklık sergileyen kripto varlık dinamikleri karşısında işlevsiz

kalması, araştırmacıları ardışık bağımlılıkları kavrayabilen ve gradyan kaybı yaşamadan "uzun vadeli hafızayı" koruyabilen LSTM ağlarına mecbur bırakmıştır.

Ancak ampirik bulgular şüpheye yer bırakmayacak biçimde göstermektedir ki; salt tarihsel açılış ve kapanış fiyatlarına dayanan "yalın" bir LSTM mimarisi, günümüzün yüksek frekanslı ticaret standartları için tek başına yeterli değildir. Yapay zeka ve kantitatif araştırma ekosistemi hızla boyut değiştirerek; gürültülü ve durağan olmayan sinyalin VMD veya CEEMDAN gibi kompleks matematiksel yöntemlerle ön filtreden geçirildiği, uzamsal ve doğrusal olmayan istatistiksel desteklerin CNN veya XGBoost gibi asimetrik algoritmalar ile birleştirildiği, sosyal medya histerisini/psikolojisini ölçmek için FinBERT benzeri Doğal Dil İşleme (NLP) modelleriyle beslenen ve tüm bu devasa veri mimarisinin Optuna veya Genetik Algoritmalarca sıfır müdahale ile otomatik optimize edildiği sofistike "hibrit tahmin orkestrasyonlarına" dönüşmüştür.

Elde edilen sonuçlar, bu çok katmanlı, yatırımcı duyarlılığı-bilinçli (sentiment-informed), dikkat ağırlıklarıyla (Attention Mechanism) desteklenen çift yönlü (Bi-LSTM) yapıların hem gün içi saatlik dalgalanmalarda hem de 30 günlük makro piyasa döngülerinde literatürün önceki standartlarına kıyasla devasa hata oranı düşüşleri (RMSE ve MAPE bazında) sağladığını doğrulamaktadır. Modellerin yalnızca laboratuvar ve test setindeki istatistiksel üstünlüklerinin, reel piyasalardaki ticari başarıya (Sharpe Rasyosu ve ekonomik geçerlilik) dönüştürülmesi ile birlikte, derin öğrenme mekanizmaları finansal piyasalardaki bireysel ve kurumsal yatırımcı arasındaki asimetrik bilgi engellerini kalıcı olarak ortadan kaldırma potansiyeline sahip olacaktır. Geleceğin araştırma ve endüstri ufku; yalnızca devasa verileri körlemesine işleyip öğrenen değil, aynı zamanda Açıklanabilir Yapay Zeka (XAI) ve SHAP değerleri gibi araçlarla "al/sat" kararlarının yapısal ve nedensel sebeplerini insan faktörüne matematiksel doğrulukla kanıtlayabilen (interpretable) hibrit ağlar üzerinde şekillenecektir.

Alıntılanan çalışmalar

1. CRYPTO PRICE PREDICTION USING LSTM+XGBOOST Identify applicable funding agency here. If none, delete this. - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/html/2506.22055v1>
2. Bitcoin Price Forecasting Based on Hybrid Variational Mode Decomposition and Long Short Term Memory Network - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/html/2510.15900v1>
3. Bitcoin Price Prediction: A Systematic Literature Review and Bibliometric Analysis - IEEE Xplore, erişim tarihi Mayıs 31, 2026, <https://ieeexplore.ieee.org/iel8/11354996/11354997/11355086.pdf>
4. Optuna Based Optimized Transformer Model Approach in Bitcoin Time Series Analysis, erişim tarihi Mayıs 31, 2026, <https://ieeexplore.ieee.org/document/10510091/>
5. Bitcoin Price Prediction Based on CNN-Bi-LSTM-Attention Model, erişim tarihi Mayıs 31, 2026, <https://drpress.org/ojs/index.php/HBEM/article/download/10540/10256/10320>
6. A HYBRID MODEL FOR BITCOIN PRICE PREDICTION - TIJER, erişim tarihi Mayıs 31,

- 2026, <https://tijer.org/tijer/papers/TIJERE001018.pdf>
7. Bitcoin Price Prediction with LSTM & PROPHET | PDF | Cryptocurrency | Forecasting, erişim tarihi Mayıs 31, 2026, <https://www.scribd.com/document/949102500/Final-Paper>
 8. FinBERT-BiLSTM: A Deep Learning Model for Predicting Volatile Cryptocurrency Market Prices Using Market Sentiment Dynamics - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/html/2411.12748v1>
 9. Comparative Study of Bitcoin Price Prediction - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/html/2405.08089v1>
 10. Bitcoin Price Prediction using Long Short Term Memory Neural Networks - IEEE Xplore, erişim tarihi Mayıs 31, 2026, <https://ieeexplore.ieee.org/document/9960055/>
 11. LSTM Forecasting Overview - Emergent Mind, erişim tarihi Mayıs 31, 2026, <https://www.emergentmind.com/topics/long-short-term-memory-lstm-forecasting>
 12. Bi-LSTM Price Prediction based on Attention Mechanism - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/html/2212.03443v2>
 13. Real-Time Bitcoin Price Prediction Using Hybrid 2D-CNN LSTM Model - ResearchGate, erişim tarihi Mayıs 31, 2026, https://www.researchgate.net/publication/370492540_Real-Time_Bitcoin_Price_Prediction_Using_Hybrid_2D-CNN_LSTM_Model
 14. Bitcoin Price Prediction Based on CNN-Bi-LSTM-Attention Model - ResearchGate, erişim tarihi Mayıs 31, 2026, https://www.researchgate.net/publication/373761768_Bitcoin_Price_Prediction_Based_on_CNN-Bi-LSTM-Attention_Model
 15. (PDF) Bitcoin Price Forecasting Based on Hybrid Variational Mode Decomposition and Long Short Term Memory Network - ResearchGate, erişim tarihi Mayıs 31, 2026, https://www.researchgate.net/publication/393538744_Bitcoin_Price_Forecasting_Based_on_Hybrid_Variational_Mode_Decomposition_and_Long_Short_Term_Memory_Network
 16. Application of Explainable AI in Machine Learning models to identify, erişim tarihi Mayıs 31, 2026, <https://repositorio.ucp.pt/bitstreams/85cf4624-f88b-4fbc-9c4a-9fa4023bb407/download>
 17. ALGORITHMIC TRADING WITH CRYPTOCURRENCIES - WHAT IS THE OPTIMAL MODELLING DESIGN FOR BITCOIN PRICE AND TREND PREDICTION? Jannik - RUN, erişim tarihi Mayıs 31, 2026, <https://run.unl.pt/bitstreams/4b1db1f5-5914-47f4-9cae-b9cba0820685/download>
 18. Real-Time Bitcoin Price Prediction Using Hybrid 2D-CNN LSTM Model - SID, erişim tarihi Mayıs 31, 2026, https://www.sid.ir/en/VEWSSID/S_pdf/2023-e057.pdf
 19. Performance Comparison of LSTM and GRU Methods in Predicting Cryptocurrency Closing Prices | Satria Andromeda | Sistemasi: Jurnal Sistem Informasi, erişim tarihi Mayıs 31, 2026,

- <https://sistemasi.ftik.unisi.ac.id/index.php/stmsi/article/view/4880>
20. Deep learning based stock price prediction - reposiTUm, erişim tarihi Mayıs 31, 2026,
<https://repositum.tuwien.at/bitstream/20.500.12708/227287/1/Tang%20Fung%20Yee%20-%202026%20-%20Deep%20learning%20based%20stock%20price%20prediction.pdf>
 21. FinBERT-BiLSTM: a deep learning model for predicting volatile cryptocurrency market prices using market sentiment dynamics | Request PDF - ResearchGate, erişim tarihi Mayıs 31, 2026,
https://www.researchgate.net/publication/400787829_FinBERT-BiLSTM_a_deep_learning_model_for_predicting_volatile_cryptocurrency_market_prices_using_market_sentiment_dynamics
 22. Financial time series forecasting model based on CEEMDAN and LSTM - ResearchGate, erişim tarihi Mayıs 31, 2026,
https://www.researchgate.net/publication/329632552_Financial_time_series_forecasting_model_based_on_CEEMDAN_and_LSTM
 23. [2510.15900] Bitcoin Price Forecasting Based on Hybrid Variational Mode Decomposition and Long Short Term Memory Network - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/abs/2510.15900>
 24. A Review of Bitcoin Price Prediction Models - Atlantis Press, erişim tarihi Mayıs 31, 2026, <https://www.atlantispress.com/article/126021753.pdf>
 25. Research on the applicability of time series models for bitcoin price prediction: Taking ARIMA and LSTM as examples, erişim tarihi Mayıs 31, 2026,
https://www.shs-conferences.org/articles/shsconf/pdf/2025/16/shsconf_icfmde2025_01010.pdf
 26. [2506.22055] crypto price prediction using lstm+xgboost - arXiv, erişim tarihi Mayıs 31, 2026, <https://arxiv.org/abs/2506.22055>
 27. Bitcoin Trend Prediction with Attention-Based Deep Learning Models and Technical Indicators - MDPI, erişim tarihi Mayıs 31, 2026,
<https://www.mdpi.com/2079-8954/12/11/498>
 28. Statistics and Artificial-Intelligence-Based Price Prediction of, erişim tarihi Mayıs 31, 2026, <https://encyclopedia.pub/entry/48442>
 29. FinBERT-BiLSTM: A Deep Learning Model for Predicting Volatile Cryptocurrency Market Prices Using Market Sentiment Dynamics - IDEAS/RePEc, erişim tarihi Mayıs 31, 2026, <https://ideas.repec.org/p/arx/papers/2411.12748.html>
 30. Understanding Bitcoin Price Prediction Trends under Various Hyperparameter Configurations - MDPI, erişim tarihi Mayıs 31, 2026, <https://www.mdpi.com/2073-431X/11/11/167>
 31. Cryptocurrency Price Prediction with Genetic Algorithm-based Hyperparameter Optimization, erişim tarihi Mayıs 31, 2026,
https://www.researchgate.net/publication/389417745_Cryptocurrency_Price_Prediction_with_Genetic_Algorithm-based_Hyperparameter_Optimization
 32. Forecasting Flower Prices by Long Short-Term Memory Model with Optuna -

- MDPI, erişim tarihi Mayıs 31, 2026, <https://www.mdpi.com/2079-9292/13/18/3646>
33. [Literature Review] A Novel Hybrid Approach Using an Attention-Based Transformer + GRU Model for Predicting Cryptocurrency Prices - Moonlight, erişim tarihi Mayıs 31, 2026, <https://www.themoonlight.io/en/review/a-novel-hybrid-approach-using-an-attention-based-transformer-gru-model-for-predicting-cryptocurrency-prices>
34. Cryptocurrency Price Prediction Using Frequency Decomposition and Deep Learning, erişim tarihi Mayıs 31, 2026, <https://www.mdpi.com/2504-3110/7/10/708>